CONGRESSO UPAV 2026 — MADRID

XL Congresso Panamericano de Avaliação — Concurso de Ponencias Técnicas

Eixo temático: a) Inteligência artificial e novas tecnologias aplicadas à valoração

MODELAGEM HÍBRIDA PARA AVALIAÇÃO DE IMÓVEIS COM REDES NEURAIS KOLMOGOROV–ARNOLD E REGRESSÃO SIMBÓLICA

Resumo

A avaliação imobiliária tem sido historicamente baseada em modelos lineares, amplamente dominados pelos analistas e valorizados por sua interpretabilidade, porém limitados na representação de não linearidades inerentes ao mercado imobiliário. O avanço das técnicas de aprendizado de máquina introduziu modelos mais flexíveis, como redes neurais perceptron de múltiplas camadas, ou multilayer perceptron (MLP), capazes de capturar relações complexas, mas à custa de elevada complexidade paramétrica, devido às funções matemáticas altamente complexas, forte dependência de volume de dados e baixa transparência analítica, configurando modelos “caixa-preta” inadequados a ambientes regulatórios e legais.

Este artigo propõe a combinação de redes neurais Kolmogorov–Arnold (KAN) e regressão simbólica (SR) como alternativa para modelagem na avaliação imobiliária. As redes KAN, recentemente propostas e em rápida expansão no campo do aprendizado de máquinas, fundamentam-se no teorema da representação de Kolmogorov–Arnold e estruturam-se a partir de funções univariadas, usualmente polinomiais, organizadas de forma aditiva, permitindo melhor captura de não linearidades, maior desempenho, menor complexidade estrutural e expressões matemáticas interpretáveis, em comparação às MLP.

A regressão simbólica, técnica oriunda da programação genética, é utilizada como mecanismo de extração de expressões analíticas a partir das relações aprendidas pelas redes KAN. A combinação KAN+SR permite converter modelos não lineares em equações matemáticas.

A abordagem proposta consolida um arcabouço metodológico que integra capacidade preditiva, parcimônia estrutural e transparência, desenvolvendo modelos de avaliação imobiliária aptos a captar as não linearidades do mercado e passíveis de interpretação e validação pelos usuários, com consistência e aderência às exigências técnicas e regulatórias. A análise foi implementada em um aplicativo desenvolvido para esta finalidade, permitindo operacionalizar a metodologia e viabilizar sua aplicação. Foram desenvolvidos estudos de caso, nos quais a metodologia demonstrou capacidade preditiva e transparência analítica.

Palavras-chave: avaliação imobiliária; redes Kolmogorov–Arnold; regressão simbólica; aprendizado de máquina interpretável; modelagem híbrida.

Resumen

La valuación inmobiliaria se ha basado históricamente en modelos lineales, ampliamente dominados por los analistas y valorados por su interpretabilidad, aunque limitados en la representación de las no linealidades inherentes al mercado inmobiliario. El avance de las técnicas de aprendizaje automático introdujo modelos más flexibles, como las redes neuronales perceptrón multicapa, o multilayer perceptron (MLP), capaces de capturar relaciones complejas, pero a costa de una elevada complejidad paramétrica, debido a funciones matemáticas altamente complejas, una fuerte dependencia del volumen de datos y una baja transparencia analítica, configurando modelos “caja negra” inadecuados para entornos regulatorios y legales.

Este artículo propone la combinación de redes neuronales de Kolmogórov–Arnold (KAN) y regresión simbólica (SR) como alternativa para la modelización en la valuación inmobiliaria. Las redes KAN, recientemente propuestas y en rápida expansión en el campo del aprendizaje automático, se fundamentan en el teorema de representación de Kolmogórov–Arnold y se estructuran a partir de funciones univariadas, usualmente polinómicas, organizadas de forma aditiva, lo que permite una mejor captura de las no linealidades, un mayor desempeño, una menor complejidad estructural y expresiones matemáticas interpretables, en comparación con las MLP.

La regresión simbólica, técnica proveniente de la programación genética, se utiliza como mecanismo de extracción de expresiones analíticas a partir de las relaciones aprendidas por las redes KAN. La combinación KAN+SR permite convertir modelos no lineales en ecuaciones matemáticas.

El enfoque propuesto consolida un marco metodológico que integra capacidad predictiva, parsimonia estructural y transparencia, desarrollando modelos de valuación inmobiliaria aptos para captar las no linealidades del mercado y susceptibles de interpretación y validación por parte de los usuarios, con consistencia y adherencia a las exigencias técnicas y regulatorias. El análisis se implementó en una aplicación desarrollada para tal fin, lo que permite operacionalizar la metodología y viabilizar su aplicación. Se desarrollaron estudios de caso, en los cuales la metodología demostró capacidad predictiva y transparencia analítica.

Palabras clave: valuación inmobiliaria; redes de Kolmogórov–Arnold; regresión simbólica; aprendizaje automático interpretable; modelización híbrida.

Abstract

Real-estate appraisal has historically relied on linear models, widely mastered by analysts and valued for their interpretability, yet limited in representing the non-linearities inherent to the real-estate market. Advances in machine-learning techniques introduced more flexible models, such as multilayer perceptron (MLP) neural networks, capable of capturing complex relationships but at the cost of high parametric complexity—owing to highly complex mathematical functions—strong dependence on data volume, and low analytical transparency, resulting in “black-box” models unsuited to regulatory and legal settings.

This paper proposes combining Kolmogorov–Arnold Network (KAN) neural networks and symbolic regression (SR) as an alternative for modeling in real-estate appraisal. KANs, recently proposed and rapidly expanding in the field of machine learning, are grounded in the Kolmogorov–Arnold representation theorem and are structured from univariate functions—usually polynomial—organized additively, allowing better capture of non-linearities, higher performance, lower structural complexity, and interpretable mathematical expressions compared with MLPs.

Symbolic regression, a technique derived from genetic programming, is used as a mechanism for extracting analytical expressions from the relationships learned by KANs. The KAN+SR combination makes it possible to convert non-linear models into mathematical equations.

The proposed approach consolidates a methodological framework that integrates predictive capacity, structural parsimony, and transparency, developing real-estate appraisal models capable of capturing market non-linearities and amenable to interpretation and validation by users, with consistency and adherence to technical and regulatory requirements. The analysis was implemented in an application developed for this purpose, enabling the methodology to be operationalized and applied. Case studies were developed in which the methodology demonstrated predictive capacity and analytical transparency.

Keywords: real-estate appraisal; Kolmogorov–Arnold Networks; symbolic regression; interpretable machine learning; hybrid modeling

Índice

1 Introdução 4
2 Referencial teórico 5
2.1 Avaliação imobiliária e modelos hedônicos 5
2.2 Limitações da regressão linear na modelagem imobiliária 6
2.3 Redes neurais artificiais na avaliação imobiliária 6
2.4 Redes Kolmogorov–Arnold (KAN) 6
2.5 Regressão simbólica e descoberta de formas funcionais 6
2.6 Integração entre KAN e regressão simbólica 7
2.7 Enquadramento normativo: ABNT NBR 14653-1 e 14653-2 7
3 Metodologias: quatro famílias e seis configurações 7
3.1 Regressão linear múltipla por mínimos quadrados ordinários (OLS) 8
3.2 Rede Neural Artificial Perceptron multicamadas (MLP) 8
3.3 Redes Neurais Artificiais Kolmogorov–Arnold (KAN) 9
3.4 Regressão simbólica (SR) 10
4 Materiais e métodos 10
4.1 Fonte e integração dos dados 10
4.2 Variáveis do modelo 11
4.3 Tratamento da localização: o CEP como variável proxy 12
4.4 Pré-processamento e divisão amostral 12
4.5 Configuração dos modelos 13
4.6 Métricas de avaliação 13
5 Resultados 14
5.1 Desempenho comparativo 14
5.2 KAN — melhor desempenho e interpretabilidade 14
5.3 KAN+SR — equação simbólica frente ao modelo linear 15
5.4 OLS Box–Cox — referência normativa clássica 15
5.5 Redes MLP 16
5.6 Regressão simbólica isolada 16
5.7 Análise gráfica — previstos vs. observados e resíduos por padrão 16
5.8 Análise dos resíduos em função dos valores previstos 17
6 Discussão 18
6.1 KAN frente à MLP: a vantagem das B-splines 19
6.2 Interpretabilidade e auditabilidade 19
6.3 Aderência normativa e juízo profissional 19
6.4 Limitações 20
7 Conclusões 20
Nota metodológica sobre o uso de inteligência artificial 21
Referências 21
Anexos 24

1 Introdução

A avaliação de imóveis ocupa posição central em decisões econômicas, jurídicas e administrativas, fazendo-se presente em financiamentos, garantias reais, partilhas, desapropriações, perícias judiciais, tributação e registros contábeis. No Brasil, a atividade é disciplinada pelas normas ABNT NBR 14653-1, que fixa os procedimentos gerais da avaliação de bens, e ABNT NBR 14653-2, específica para imóveis urbanos, as quais estabelecem os métodos admitidos e os critérios de enquadramento dos laudos quanto ao grau de fundamentação e ao grau de precisão (ABNT, 2019; ABNT, 2011). O método mais difundido é o comparativo direto de dados de mercado, operacionalizado por inferência estatística e, na prática corrente, pela regressão linear múltipla estimada por mínimos quadrados ordinários (OLS).

O modelo hedônico clássico, formalizado por Rosen (1974), decompõe o preço de um bem heterogêneo como função de seus atributos, refletindo de forma implícita o valor marginal de cada característica estrutural, locacional e econômica. Na prática, a função é em geral especificada de forma linear ou log-linear, o que permite interpretar diretamente os coeficientes como variações marginais ou elasticidades. Diversos estudos empíricos, contudo, indicam que atributos fundamentais — área privativa, idade, padrão construtivo e localização — guardam relações não lineares com o preço, incluindo retornos marginais decrescentes, efeitos de saturação e interações entre características (MALPEZZI, 2003; GOODMAN; THIBODEAU, 1998). Além disso, as hipóteses clássicas do OLS — linearidade, homoscedasticidade, normalidade dos resíduos e ausência de multicolinearidade severa — raramente são integralmente satisfeitas em bases imobiliárias reais (GREENE, 2018; WOOLDRIDGE, 2016), o que compromete a eficiência dos estimadores e a capacidade preditiva fora da amostra de calibração.

Como resposta a essas limitações, técnicas de aprendizado de máquina, em especial as redes neurais do tipo perceptron multicamadas (MLP), passaram a ser exploradas na avaliação imobiliária. As MLP são aproximadores universais de funções (CYBENKO, 1989; HORNIK; STINCHCOMBE; WHITE, 1989) e apresentam elevada flexibilidade para capturar não linearidades e interações, frequentemente superando os modelos lineares em desempenho preditivo (ZURADA; LEVITAN; GUAN, 2011; MORA-GARCIA; CESPEDES-LOPEZ; PEREZ-SANCHEZ, 2022). Entretanto, operam como estruturas de caixa-preta, que dificultam a interpretação econômica dos resultados e a rastreabilidade das decisões modeladas (BISHOP, 2006; HAYKIN, 2009); demandam volumes elevados de dados e são propensas ao sobreajuste (overfiting) — fenômeno em que o modelo se ajusta excessivamente às particularidades da amostra de treinamento, perdendo capacidade de generalização para dados novos — em amostras reduzidas. Essas características restringem sua adoção em ambientes nos quais a transparência, a explicabilidade e a auditabilidade são requisitos essenciais, como o pericial e o regulatório.

Nesse cenário, as redes neurais Kolmogorov–Arnold (KAN) emergem como alternativa conceitualmente distinta para a modelagem de dados tabulares (LIU et al., 2024). Fundamentadas no teorema da representação de Kolmogorov–Arnold (KOLMOGOROV, 1957; ARNOLD, 1957), segundo o qual toda função contínua multivariada pode ser escrita como superposição de funções contínuas de uma variável, as KAN deslocam a não linearidade dos nós para as arestas, modelando-a por funções univariadas parametrizadas — tipicamente B-splines. Essa concepção aproxima a rede da lógica dos modelos hedônicos, pois cada função aprendida pode ser associada ao efeito marginal de uma variável explicativa, sem que se imponha a priori sua forma funcional. A interpretação direta dessas funções, todavia, permanece limitada enquanto elas são representadas numericamente por splines.

Para superar essa limitação, recorre-se à regressão simbólica (SR, do inglês symbolic regression), técnica oriunda da programação genética (KOZA, 1994) que busca descobrir explicitamente a forma funcional que relaciona as variáveis, produzindo equações fechadas, parcimoniosas e auditáveis (SCHMIDT; LIPSON, 2009; CRANMER, 2023). A integração entre

KAN e SR permite destilar o modelo neural em uma expressão algébrica, reconciliando a flexibilidade dos modelos de aprendizado com a transparência matemática exigida em aplicações normativas e periciais — superando a dicotomia tradicional entre modelos estatísticos interpretáveis e modelos de alto desempenho, porém opacos.

A proposta dialoga diretamente com o lema do Congresso UPAV 2026 — "Valoración, inteligencia artificial y juicio profesional". A abordagem aqui defendida não substitui o avaliador por um algoritmo: ao converter o modelo de aprendizado em uma equação auditável, devolve ao profissional o controle interpretativo, permitindo crítica, validação de sanidade econômica e sustentação técnica do valor estimado. A inteligência artificial atua, assim, como instrumento a serviço do juízo profissional, e não em seu lugar.

O objetivo deste trabalho é comparar, sobre uma base real de 15.000 apartamentos do município de São Paulo que integra registros de ITBI e IPTU, seis abordagens de modelagem: (i) KAN; (ii) KAN+SR, com destilação simbólica multivariada; (iii) regressão linear (OLS) com transformações Box–Cox; (iv) MLP de uma camada oculta; (v) MLP de duas camadas ocultas; e (vi) regressão simbólica isolada. A análise concentra-se em quatro dimensões: capacidade preditiva, modelagem das não linearidades, parcimônia estrutural e interpretabilidade das equações de saída. Três perguntas norteiam a investigação: (i) a KAN supera, em capacidade preditiva, o OLS e as MLP de profundidade semelhante? (ii) a destilação simbólica preserva o desempenho da rede, com perda controlada de fidelidade? e (iii) a equação destilada é *não inferior* ao OLS — isto é, não apresenta desempenho preditivo relevantemente pior —, oferecendo, em contrapartida, forma fechada e auditável? A terceira pergunta é deliberadamente formulada como hipótese de não inferioridade, e não de superioridade, dada a pequena diferença esperada entre a equação destilada e o modelo linear. Como contribuições, destacam-se: a aplicação, no campo da avaliação imobiliária, da destilação KAN→SR multivariada, capaz de preservar interações entre variáveis; a comparação entre KAN e MLP sob profundidade semelhante, que evidencia o efeito das funções de aresta (B-splines aprendidas) frente às ativações fixas — ainda que sob orçamentos distintos de parâmetros, conforme se pondera na Seção 6.1; e a disponibilização pública da base de dados utilizada.

O restante do artigo está organizado da seguinte forma. A Seção 2 apresenta o referencial teórico. A Seção 3 define as quatro famílias metodológicas empregadas — e as seis configurações delas derivadas —, com tratamento mais detalhado das KAN e da regressão simbólica. A Seção 4 descreve os materiais e métodos — origem e integração dos dados, variáveis, tratamento da localização, pré-processamento e configuração dos modelos. A Seção 5 reporta os resultados; a Seção 6 os discute; e a Seção 7 apresenta as conclusões. Encerram o trabalho a nota metodológica sobre o uso de inteligência artificial, as referências e os anexos com as formulações completas.

2 Referencial teórico

2.1 Avaliação imobiliária e modelos hedônicos

A avaliação imobiliária fundamenta-se, em grande medida, na teoria dos preços hedônicos, segundo a qual o valor de um bem heterogêneo pode ser expresso como função de seus atributos individuais. O arcabouço foi formalizado por Rosen (1974), que demonstrou refletir o preço de mercado o valor marginal implícito de características estruturais, locacionais e ambientais. Desde então, os modelos hedônicos consolidaram-se como principal base empírica dos estudos de mercado imobiliário e das aplicações normativas e periciais (MALPEZZI, 2003). Na prática, são usualmente estimados por regressão linear múltipla, em razão de sua simplicidade, interpretabilidade e ampla aceitação normativa; transformações logarítmicas são frequentes para capturar elasticidades constantes e mitigar a heterocedasticidade.

2.2 Limitações da regressão linear na modelagem imobiliária

Apesar de sua difusão, a regressão linear apresenta limitações reconhecidas na modelagem imobiliária. Atributos como área, idade e localização exibem relações não lineares com o preço, cuja representação por meio do OLS exige a inclusão de termos polinomiais ou de interações especificadas a priori, o que tende a produzir modelos instáveis, sensíveis à multicolinearidade e de difícil interpretação econômica (GOODMAN; THIBODEAU, 1998; GREENE, 2018). Acresce que a validade inferencial do OLS depende de hipóteses — linearidade, homoscedasticidade, normalidade e ausência de multicolinearidade severa — recorrentemente violadas em dados reais (WOOLDRIDGE, 2016). Violações de homoscedasticidade, embora não enviesem as estimativas pontuais, comprometem a eficiência e a inferência sobre os coeficientes, demandando estimadores robustos (WHITE, 1980).

2.3 Redes neurais artificiais na avaliação imobiliária

Como alternativa não linear, as redes neurais artificiais — sobretudo as MLP — passaram a ser aplicadas à avaliação imobiliária. Por serem aproximadores universais (CYBENKO, 1989; HORNIK; STINCHCOMBE; WHITE, 1989), capturam não linearidades e interações complexas, com ganhos preditivos relatados em mercados heterogêneos (ZURADA; LEVITAN; GUAN, 2011; MORA-GARCIA; CESPEDES-LOPEZ; PEREZ-SANCHEZ, 2022). A literatura também documenta suas limitações em contextos avaliatórios: baixa interpretabilidade, decorrente de seu caráter de caixa-preta (BISHOP, 2006; HAYKIN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016; RUDIN, 2019); elevada demanda de dados; e risco de sobreajuste (conforme definido na Seção 1) em amostras pequenas. Tais fatores motivam a busca por modelos que conciliem desempenho e transparência. Aplicações recentes no âmbito da valoração de imóveis públicos nacionais corroboram a viabilidade técnica dessas abordagens, demonstrando que modelos de aprendizagem de máquina — redes neurais e gradient boosting — podem gerar estimativas de valor de mercado com razoável assertividade e abrangência geográfica nacional (SOUZA NETO; MIURA; LADEIRA, 2023).

2.4 Redes Kolmogorov–Arnold (KAN)

As KAN constituem arquitetura recente, proposta por Liu et al. (2024) e inspirada no teorema de Kolmogorov–Arnold (KOLMOGOROV, 1957; ARNOLD, 1957). Diferentemente das MLP, que concentram a não linearidade em funções de ativação fixas aplicadas aos nós, as KAN substituem cada peso escalar por uma função univariada aprendível, em geral uma B-spline, posicionada na aresta. A não linearidade passa, assim, a ser distribuída pelas conexões. Essa concepção confere às KAN maior capacidade de capturar não linearidades suaves com economia de parâmetros e, sobretudo, interpretabilidade estrutural: cada função de aresta pode ser visualizada e associada ao efeito de uma variável. Evidências recentes apontam desempenho competitivo das KAN em problemas de regressão tabular, inclusive em cenários de dados escassos, e a literatura aplicada já registra usos em previsão imobiliária (VIKTORATOS; TSADIRAS, 2025) e em séries temporais financeiras (LIU et al., 2024; GENET; INZIRILLO, 2024).

2.5 Regressão simbólica e descoberta de formas funcionais

A regressão simbólica distingue-se da regressão tradicional por não estimar apenas parâmetros de uma forma fixa, mas por procurar a própria forma funcional que relaciona as variáveis. Sua origem está na programação genética, sistematizada por Koza (1994), na qual expressões matemáticas, representadas como árvores, são evoluídas por operadores inspirados na seleção natural — mutação, recombinação e seleção — sob critérios simultâneos de acurácia e parcimônia. Métodos modernos lidam com dados ruidosos e impõem controle explícito de complexidade (SCHMIDT; LIPSON, 2009), tendo sido aplicados com sucesso à descoberta de leis em física, engenharia e economia. A biblioteca PySR, baseada em SymbolicRegression.jl, implementa busca evolutiva de alto desempenho e

tornou-se referência prática na área (CRANMER, 2023). Aplicações recentes documentam o uso bem-sucedido da regressão simbólica na modelagem de preços de ativos financeiros, tanto em contextos de precificação de ações (ZUO; JIANG, 2025) como em previsão de preços de commodities (DRACHAL; PAWLOWSKI, 2024), evidenciando a generalidade do método para problemas de valoração complexos.

2.6 Integração entre KAN e regressão simbólica

As KAN fornecem uma representação funcional intermediária altamente informativa, enquanto a regressão simbólica converte essa representação em equações algébricas fechadas e auditáveis. A literatura ainda é incipiente quanto à integração sistemática das duas abordagens na avaliação imobiliária. O presente trabalho explora justamente essa lacuna, ao tratar a KAN como estimador de alta capacidade e a regressão simbólica como mecanismo de destilação interpretativa. O procedimento é análogo, em espírito, à destilação de conhecimento de redes neurais (HINTON; VINYALS; DEAN, 2015) e à lógica dos modelos substitutos (*surrogate models*) — abordagem da literatura de aprendizado interpretável que, em decisões de alto risco, defende o uso de modelos inerentemente transparentes (RUDIN, 2019). O objetivo é obter uma equação que preserve o comportamento aprendido pela rede e satisfaça os requisitos de transparência das normas de avaliação.

2.7 Enquadramento normativo: ABNT NBR 14653-1 e 14653-2

As normas ABNT NBR 14653-1 (ABNT, 2019) e NBR 14653-2 (ABNT, 2011) regem, respectivamente, os procedimentos gerais e a avaliação de imóveis urbanos. Para o método comparativo por inferência estatística, a NBR 14653-2 estabelece dois enquadramentos distintos e independentes. O grau de fundamentação avalia o rigor do trabalho e baseia-se em critérios como a quantidade mínima de dados de mercado efetivamente utilizados em função do número de variáveis, a identificação e a rastreabilidade desses dados e a ausência de extrapolações. O grau de precisão, por sua vez, refere-se à qualidade da estimativa e é aferido pela amplitude do intervalo de confiança de 80% em torno do valor. Cabe ressaltar uma distinção metodológica frequentemente negligenciada na prática: a norma não fixa limiares mínimos do coeficiente de determinação (R^2) como critério de enquadramento. O R^2 e demais métricas de erro empregados neste estudo devem, portanto, ser entendidos como indicadores de desempenho preditivo consagrados na literatura de aprendizado de máquina, e não como condição normativa de grau — embora subsidiem, em conjunto com os intervalos de confiança e a análise de resíduos, a avaliação técnica da qualidade do modelo.

3 Metodologias: quatro famílias e seis configurações

Esta seção define as quatro famílias metodológicas comparadas no estudo — OLS, MLP, KAN e regressão simbólica —, das quais derivam as seis configurações avaliadas (KAN; KAN+SR; OLS Box–Cox; MLP de uma e de duas camadas; e SR isolada), reportadas na Seção 5. A regressão linear por mínimos quadrados ordinários (OLS) e o perceptron multicamadas (MLP), por serem amplamente conhecidos, são apresentados de forma sucinta. As redes Kolmogorov–Arnold (KAN) e a regressão simbólica (SR), que constituem o núcleo da proposta, recebem tratamento mais detalhado. A Figura 1 sintetiza o arcabouço: a KAN atua como estimador não linear de alta capacidade e a regressão simbólica destila o modelo aprendido em uma equação fechada, passível de inspeção e validação pelo avaliador.

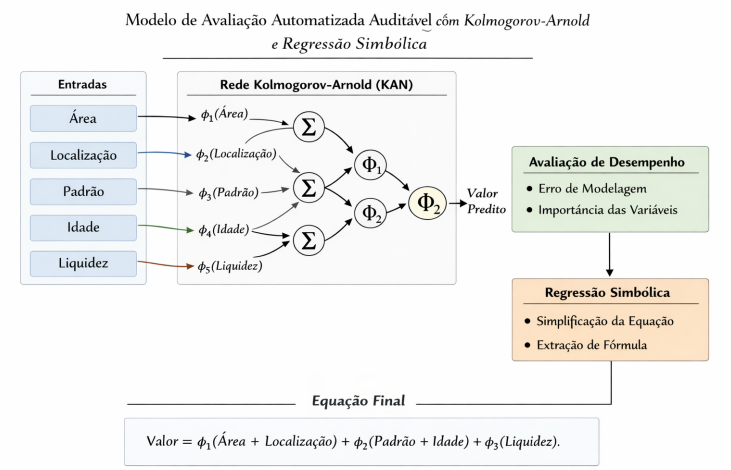


Figura 1 — Arcabouço conceitual da abordagem híbrida KAN+SR: as variáveis de entrada alimentam a rede Kolmogorov–Arnold, cujas funções de aresta são destiladas por regressão simbólica em uma equação final auditável. Esquema ilustrativo; o modelo implementado emprega 12 variáveis (Seção 4.2).
Fonte: elaboração própria.

3.1 Regressão linear múltipla por mínimos quadrados ordinários (OLS)

A regressão linear múltipla é o modelo de referência da avaliação imobiliária e, neste estudo, a representante do paradigma estatístico clássico. O modelo hedônico assume que a variável dependente — aqui, o logaritmo do valor por metro quadrado — é função linear dos atributos:

$$\ln(V/m^2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k + \varepsilon$$

em que β_k são os coeficientes e ε o termo de erro aleatório. Os parâmetros são estimados por mínimos quadrados ordinários, que minimizam a soma dos quadrados dos resíduos. Para flexibilizar a forma funcional sem abandonar o arcabouço linear, aplicam-se transformações de Box–Cox (BOX; COX, 1964) às variáveis contínuas, definidas por $(x^\lambda - 1)/\lambda$ para $\lambda \neq 0$ e por $\ln(x)$ para $\lambda = 0$, com o parâmetro λ estimado por máxima verossimilhança exclusivamente no conjunto de treino. A seleção de variáveis foi conduzida por procedimento stepwise — método que adiciona ou remove variáveis explicativas uma a uma, em etapas sequenciais, com base em critério estatístico — orientado pelo critério de informação de Akaike (AIC), medida que penaliza a verossimilhança do modelo pelo número de parâmetros estimados, promovendo o equilíbrio entre ajuste e parcimônia e desincentivando a inclusão de variáveis redundantes. Embora transparente e de fácil auditoria, o modelo permanece restrito a transformações globais previamente especificadas e sujeito às hipóteses clássicas (GREENE, 2018).

3.2 Rede Neural Artificial Perceptron multicamadas (MLP)

O perceptron multicamadas é a rede neural de referência e representa o paradigma de aprendizado de máquina de uso consagrado. Uma MLP com uma camada oculta exprime-se como:

$$\hat{y} = W_2 \cdot g(W_1 \cdot x + b_1) + b_2$$

em que W_1 e W_2 são matrizes de pesos, b_1 e b_2 vetores de viés e g uma função de ativação não linear — neste trabalho, a função ReLU (Rectified Linear Unit), definida por $g(z) = \max(0, z)$, que retorna zero para entradas negativas e a própria entrada para positivas, introduzindo não linearidade de forma computacionalmente eficiente. O treinamento minimiza o erro quadrático médio por retropropagação e otimização por gradiente (HAYKIN, 2009; GOODFELLOW; BENGIO; COURVILLE, 2016). As MLP são aproximadores universais, porém a função aprendida resulta de uma composição de hiperplanos lineares por partes, sem forma algébrica explícita e de difícil interpretação econômica. Foram avaliadas arquiteturas de uma e de duas camadas ocultas, com regularização por dropout — técnica que desativa aleatoriamente uma fração dos neurônios a cada iteração do treinamento,

reduzindo a dependência excessiva entre unidades — e decaimento de pesos (weight decay), penalização dos pesos durante a otimização que desincentiva soluções de grande magnitude e controla o sobreajuste, para conter o ajuste excessivo.

3.3 Redes Neurais Artificiais Kolmogorov–Arnold (KAN)

As redes Kolmogorov–Arnold fundamentam-se no teorema da representação de Kolmogorov–Arnold (KOLMOGOROV, 1957; ARNOLD, 1957), segundo o qual toda função contínua de n variáveis pode ser representada por uma superposição finita de funções contínuas de uma única variável e da operação de adição:

$$f(x_1, \ldots, x_n) = \Sigma\ (q = 0, \ldots, 2n)\ \ \Phi_q\ (\ \Sigma\ (p = 1, \ldots, n)\ \ \varphi_q,p(x_p)\ )$$

em que φ_q,p e Φ_q são funções univariadas contínuas. Liu et al. (2024) generalizaram esse resultado para uma arquitetura de aprendizado profundo, na qual cada peso escalar das redes tradicionais é substituído por uma função univariada aprendível, posicionada na aresta que conecta dois nós. Ao passo que a MLP aplica funções de ativação fixas nos nós, a KAN aprende a própria forma das funções nas conexões; os nós apenas somam os sinais que chegam. A saída de uma KAN de duas camadas pode ser escrita como:

$$\hat{y} = \Sigma_j\ \ \psi_j\ (\ \Sigma_i\ \ \varphi_{ij}(x_i)\ )$$

em que φ_{ij} são as funções da primeira camada (uma por par variável–neurônio) e ψ_j as da segunda. Cada função univariada é parametrizada por uma B-spline, polinômio por partes de ordem k definido sobre uma grade (grid) de pontos de controle; maior número de pontos de controle e maior ordem ampliam a flexibilidade local, permitindo capturar não linearidades suaves — retornos decrescentes, saturações e inflexões — com economia de parâmetros. No presente estudo adotou-se a arquitetura [12 → 6 → 1], com splines cúbicas (k = 3) sobre grade de dez intervalos (grid = 10), totalizando cerca de 78 funções aprendidas e aproximadamente 1.014 parâmetros. O treinamento foi conduzido em três fases sucessivas, por otimização de gradiente com o algoritmo Adam (Adaptive Moment Estimation), que combina estimativas adaptativas do primeiro e do segundo momento dos gradientes para ajustar individualmente a taxa de aprendizado de cada parâmetro, acelerando a convergência e reduzindo a sensibilidade à escala das variáveis (KINGMA; BA, 2015), com regularização que penaliza a magnitude das funções e favorece a esparsidade, reduzindo a influência de variáveis irrelevantes. A Figura 2 ilustra a arquitetura.

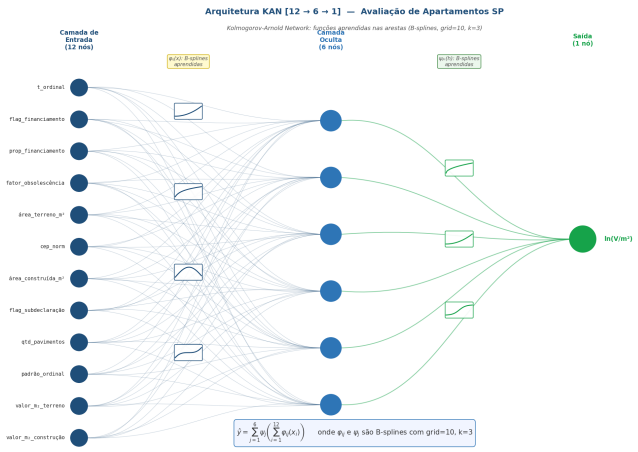


Figura 2 — Arquitetura da rede Kolmogorov–Arnold [12 → 6 → 1] empregada na avaliação dos apartamentos. Em cada aresta, uma B-spline (grid = 10, ordem k = 3) modela o efeito de uma variável; os nós da camada oculta somam as contribuições e a saída fornece o logaritmo do valor por metro quadrado.
Fonte: elaboração própria.

A principal vantagem das KAN, para os fins da engenharia de avaliações, é a interpretabilidade estrutural: como cada função de aresta depende de uma única variável, é possível visualizar o efeito marginal aprendido para cada atributo e ordená-los por importância, aproximando-se da lógica dos modelos hedônicos sem impor a forma funcional.

Em comparação com a MLP de profundidade equivalente, as B-splines aprendidas mostram-se mais expressivas do que as ativações ReLU fixas para as relações suaves e monótonas típicas do mercado imobiliário, conforme se discute na Seção 6.

3.4 Regressão simbólica (SR)

A regressão simbólica busca descobrir a expressão matemática que melhor relaciona variáveis independentes e dependente, em vez de ajustar os parâmetros de uma forma fixa. As expressões candidatas são representadas como árvores sintáticas, cujos nós internos são operadores — adição, subtração, multiplicação, divisão e funções como raiz, quadrado, cubo, exponencial e logaritmo — e cujas folhas são variáveis ou constantes. A busca é conduzida por programação genética (KOZA, 1994): uma população de expressões evolui por meio de mutação, recombinação e seleção, otimizando simultaneamente a acurácia e a parcimônia. O resultado não é uma única equação, mas uma fronteira de Pareto que confronta erro e complexidade, da qual o analista seleciona a expressão de melhor compromisso (SCHMIDT; LIPSON, 2009; CRANMER, 2023). Empregou-se a biblioteca PySR, com tamanho máximo de expressão (maxsize) igual a 20.

Duas estratégias de destilação da KAN foram investigadas. Na primeira, aditiva, ajustou-se uma expressão simbólica unidimensional a cada perfil marginal aprendido pela rede, somando-se as doze parcelas. Embora cada perfil fosse reproduzido com altíssima fidelidade ($R^2 > 0{,}95$ na maioria), a recomposição aditiva apresentou desempenho preditivo muito baixo ($R^2 = 0{,}095$), pois as camadas ocultas da KAN criam interações entre variáveis que não podem ser recuperadas por funções marginais isoladas. Na segunda estratégia, multivariada, a regressão simbólica foi treinada diretamente sobre as predições da KAN — isto é, buscou-se uma equação compacta que reproduzisse a saída da rede em função das variáveis originais, preservando as interações. Essa abordagem alcançou fidelidade elevada à rede ($R^2 = 0{,}900$ no conjunto de teste). Da fronteira de Pareto retornada pelo PySR, adotou-se a expressão de complexidade 19 como solução de melhor compromisso entre acurácia e parcimônia, apresentada na Seção 5.3 e detalhada no Anexo A. Reconhece-se, como limitação metodológica (Seção 6.4), que a inspeção do desempenho preditivo no conjunto de teste participou dessa escolha final; um protocolo plenamente independente reservaria a seleção da expressão ao conjunto de validação e restringiria o teste a uma única avaliação, após o congelamento de modelo, hiperparâmetros e equação. As métricas de teste da equação destilada devem, portanto, ser lidas como estimativa pontual, a ser confirmada em validação independente.

A título de comparação, avaliou-se ainda a regressão simbólica isolada, ajustada diretamente aos dados reais (e não às predições da KAN) por um procedimento sequencial de backfitting, com doze expressões unidimensionais. Essa variante serve de linha de base independente, permitindo distinguir o que a destilação herda da capacidade da rede daquilo que a própria regressão simbólica recupera dos dados.

4 Materiais e métodos

4.1 Fonte e integração dos dados

A base de modelagem resulta da integração de duas fontes públicas da Prefeitura do Município de São Paulo: o cadastro de transações do Imposto de Transmissão de Bens Imóveis (ITBI), que reúne os valores declarados nas escrituras de compra e venda de imóveis para fins de recolhimento do imposto municipal, e o cadastro do Imposto Predial e Territorial Urbano (IPTU), que fornece atributos físicos e fiscais dos imóveis (PMSP, 2026). Partiu-se de 132.286 transações de ITBI, integradas aos registros cadastrais do IPTU dos exercícios de 2021 e 2022 por meio do número do contribuinte (campo num_contribuinte_sql). O cruzamento alcançou índice de correspondência de 78%, do qual se extraiu, por amostragem estratificada segundo o padrão construtivo, a base final de 15.000 apartamentos residenciais. A base consolidada será disponibilizada publicamente na plataforma Kaggle, em atenção aos

princípios de reprodutibilidade e rastreabilidade dos dados de mercado preconizados pelas normas de avaliação.

Cabe registrar uma limitação estrutural importante da fonte: os valores do ITBI são declarados pelos contribuintes com vistas ao cálculo do tributo devido, o que abre a possibilidade de subdeclaração intencional — ou seja, o valor consignado pode ser inferior ao preço efetivamente praticado na transação. Essa distorção é endêmica em bases tributárias imobiliárias e não é eliminada pela disponibilização pública dos dados. Para mitigá-la, duas variáveis de controle oriundas diretamente do cadastro do ITBI foram incorporadas ao modelo: a variável binária flag_subdeclaracao, que identifica os registros nos quais o valor declarado na escritura é inferior ao valor venal de referência fixado pela Prefeitura — sinalizado pelo sistema tributário municipal como indício de subdeclaração —; e as variáveis flag_financiamento e prop_financiamento, que indicam, respectivamente, a presença de financiamento bancário e a proporção do valor financiado em relação ao total da transação. Transações com financiamento tendem a declarar valores mais próximos do preço real, pois a instituição financeira encomenda a avaliação do imóvel e o valor avaliado serve de base contratual, reduzindo o incentivo à subdeclaração.

Registre-se uma observação metodológica sobre essas três variáveis transacionais (flag_subdeclaracao, flag_financiamento e prop_financiamento): por derivarem do registro do ITBI, elas incorporam informação contemporânea à transação e cumprem, no modelo, a função explícita de controlar a *qualidade declaratória* do valor, mitigando a subdeclaração característica das bases tributárias imobiliárias. Sua manutenção no conjunto de preditores é deliberada: na configuração avaliada, tais variáveis corrigem o viés de declaração e aproximam as estimativas dos valores efetivamente praticados, de modo que sua remoção degradaria essa correção. Reconhece-se que, em um cenário estritamente *ex ante* — anterior à escritura —, parte dessa informação pode não estar disponível; por isso, recomenda-se, como desdobramento, uma análise de sensibilidade que quantifique o desempenho do modelo com e sem essas variáveis, distinguindo o uso pós-transação (controle declaratório) do uso estritamente preditivo, e que avalie a disponibilidade real de cada preditor na data da avaliação.

4.2 Variáveis do modelo

O modelo emprega doze variáveis explicativas — estruturais, fiscais, locacionais e transacionais — e tem por variável dependente o logaritmo natural do valor por metro quadrado de área construída. A Tabela 1 descreve o conjunto. A adoção do valor por metro quadrado, em escala logarítmica, atenua a heterocedasticidade associada à dimensão dos imóveis e estabiliza a variância dos resíduos.

Tabela 1 — Variáveis do modelo de avaliação.

Variável	Tipo	Descrição
ln(V/m²) — alvo	Contínua	Logaritmo natural do valor de transação por m² de área construída (R$/m²)
valor_m2_terreno	Contínua	Valor unitário do m² de terreno (planta genérica de valores — IPTU)
valor_m2_construcao	Contínua	Valor unitário do m² de construção (IPTU)
area_construida_m2	Contínua	Área construída/privativa do imóvel (m²)
area_terreno_m2	Contínua	Área do terreno (m²)
padrao_ordinal	Ordinal (1–6)	Padrão construtivo, de popular (1) a fino (6), conforme cadastro do IPTU
cep_norm	Contínua [0,1]	Proxy de localização: CEP normalizado (Seção 4.3)
qtd_pavimentos	Inteira	Número de pavimentos da edificação
fator_obsolescencia	Contínua	Fator de depreciação por idade e estado de conservação (IPTU)
t_ordinal	Inteira	Tempo, em meses, desde janeiro de 2021 (controle temporal da transação)

Variável	Tipo	Descrição
flag_financiamento	Binária (ITBI)	Indica a presença de financiamento bancário na transação; transações financiadas tendem a refletir valores mais próximos do mercado
prop_financiamento	Contínua [0,1] (ITBI)	Proporção do valor total da transação coberta por financiamento bancário
flag_subdeclaracao	Binária (ITBI)	Indica que o valor declarado na escritura é inferior ao valor venal de referência municipal — indício de subdeclaração fiscal do preço real da transação

Fonte: elaboração própria.

4.3 Tratamento da localização: o CEP como variável proxy

A localização foi representada pelo Código de Endereçamento Postal (CEP), tratado como variável contínua normalizada. O sistema implantado pelos Correios em 1971 (ECT, 1971) atribuiu, no município de São Paulo, faixas numéricas sequenciais alocadas por macrozona geográfica, partindo do núcleo central (faixa 01xxx) em direção às zonas periféricas (02xxx a 05xxx; 08xxx). O CEP foi convertido em inteiro de oito dígitos e normalizado para o intervalo [0,1] por transformação MinMax, com parâmetros ajustados exclusivamente sobre o conjunto de treino — de modo que valores próximos de 0 correspondem ao centro e próximos de 1 à periferia leste. A Tabela 2 resume a distribuição por macrozona. A correlação de Pearson entre o CEP normalizado e o logaritmo do valor por metro quadrado é $r = -0{,}175$ ($p < 0{,}001$), estatisticamente significativa e coerente com a gradação centro–periferia do mercado paulistano.

Tabela 2 — Macrozonas de CEP no município de São Paulo e valor unitário médio na amostra.

Faixa CEP	Macrozona	Bairros representativos	V/m² médio
01xxx	Centro / Sé	Sé, Bela Vista, Cerqueira César, Jardins, Liberdade	R$ 6.118
02xxx	Zona Norte	Santana, Tucuruvi, Vila Maria, Casa Verde	R$ 3.928
03xxx	Zona Leste (interna)	Brás, Mooca, Tatuapé, Aricanduva, Penha	R$ 4.229
04xxx	Zona Sul	Vila Mariana, Itaim Bibi, Jabaquara, Santo Amaro	R$ 5.901
05xxx	Zona Oeste	Pinheiros, Lapa, Butantã, Morumbi, Campo Limpo	R$ 4.895
08xxx	Zona Leste (extrema)	São Miguel, Itaim Paulista, Itaquera, Guaianazes	R$ 2.858

Fonte: elaboração própria.

Reconhecem-se as limitações dessa aproximação. A relação entre o número do CEP e o valor não é monotônica em todo o domínio — a Zona Sul (04xxx) supera, em média, a Zona Norte (02xxx), e uma mesma faixa pode abrigar bairros valorizados e periféricos. Além disso, o CEP possui granularidade grosseira (de uma a poucas quadras), introduz descontinuidades artificiais nas fronteiras de faixa e não captura determinantes intrinsecamente espaciais do valor, como a acessibilidade ao transporte de alta capacidade e a proximidade a polos de emprego (BIDERMAN, 2008; HWANG; THILL, 2009). Coerentemente, o CEP figurou entre os preditores de menor influência no modelo (Seção 5.2). Como evolução metodológica, recomenda-se substituí-lo por coordenadas geográficas e indicadores de acessibilidade, a partir de bases geocodificadas como a do Centro de Estudos da Metrópole (CEM/USP).

4.4 Pré-processamento e divisão amostral

A base foi dividida em treino (70%; 10.500 registros), validação (15%; 2.250) e teste (15%; 2.250), por amostragem estratificada segundo o padrão construtivo, com semente fixa (random_state = 42) para reprodutibilidade. As variáveis explicativas foram normalizadas para o intervalo [0,1] por transformação MinMax ajustada exclusivamente no conjunto de treino e aplicada, sem reajuste, à validação e ao teste, evitando vazamento de informação. A normalização MinMax foi adotada por sua interpretabilidade e por manter a forma das

distribuições, conforme indicado na literatura: Anelli et al. (2025) demonstram que a escolha da técnica de normalização afeta substancialmente a estrutura dos coeficientes e a interpretação econômica dos modelos de regressão aplicados à valoração imobiliária, recomendando transparência sobre a transformação utilizada. As métricas reportadas referem-se ao conjunto de teste. O conjunto de validação orientou a seleção de arquiteturas e de hiperparâmetros; ressalva-se, contudo, que, no caso específico da equação simbólica destilada, a escolha final da expressão na fronteira de Pareto também considerou o desempenho no teste (Seções 3.4 e 6.4), o que deve ser ponderado na leitura da respectiva métrica.

4.5 Configuração dos modelos

A KAN adotou a arquitetura [12 → 6 → 1], com grid = 10, k = 3 e treinamento em três fases por otimização Adam: (i) ajuste inicial sem regularização (500 passos, taxa de aprendizado 1×10^{-3}); (ii) refinamento após extensão da grade de 5 para 10 intervalos (300 passos, taxa 3×10^{-4}); e (iii) indução de esparsidade, com penalização de magnitude e de entropia das funções (150 passos, taxa 1×10^{-4}, $\lambda = 1\times10^{-5}$), preparando a rede para a destilação simbólica. A destilação KAN+SR treinou a regressão simbólica (PySR, sobre SymbolicRegression.jl) sobre as predições da KAN, com operadores binários +, −, × e ÷; operadores unários log, √, quadrado, cubo e exp; tamanho máximo de expressão (maxsize) igual a 20; penalização de parcimônia 5×10^{-4}; e semente 42 — selecionando-se a expressão de complexidade 19 como melhor compromisso da fronteira de Pareto (com a ressalva da Seção 3.4). O modelo OLS aplicou transformações de Box–Cox a sete variáveis contínuas — com os parâmetros λ estimados por máxima verossimilhança exclusivamente no conjunto de treino — e seleção stepwise por AIC, que reteve dez das doze variáveis. As redes MLP foram avaliadas em duas arquiteturas principais — uma camada oculta [12 → 24 → 1], com 337 parâmetros, e duas camadas ocultas [12 → 24 → 12 → 1], com 625 parâmetros —, treinadas com Adam (taxa de aprendizado 1×10^{-3}), decaimento de pesos 1×10^{-4}, agendamento de cosseno — estratégia em que a taxa de aprendizado é reduzida progressivamente seguindo uma curva cossenoidal ao longo das épocas, permitindo refinamento gradual dos pesos sem oscilações bruscas —, dropout de 0,1, parada antecipada (estratégia que interrompe o treinamento quando o desempenho no conjunto de validação deixa de melhorar por um número definido de épocas consecutivas — aqui, paciência de 60 épocas — evitando o sobreajuste) e lotes de 512. A regressão simbólica isolada empregou backfitting sequencial com doze expressões unidimensionais. Em todos os modelos empregou-se semente única (42); as versões das bibliotecas (Python, PyTorch, a implementação da KAN e PySR/SymbolicRegression.jl) e os scripts de treinamento serão disponibilizados, com dicionário de dados, junto à base. Todos os modelos avaliados — KAN, KAN+SR, OLS e MLP — foram implementados e executados por meio de scripts próprios em linguagem Python, desenvolvidos para operacionalizar a metodologia.

4.6 Métricas de avaliação

O desempenho foi aferido por quatro métricas: o coeficiente de determinação (R^2), a raiz do erro quadrático médio (RMSE) e o erro absoluto médio (MAE) foram calculados na escala de ln(V/m²), unidade em que os modelos são ajustados; o erro percentual absoluto médio (MAPE) foi calculado na escala original de valor por metro quadrado (R$/m²), após a exponenciação das predições, de modo a expressar o erro relativo em termos monetários diretamente interpretáveis. Essa distinção explica por que o MAPE (16,7%–19,8%) é da ordem de grandeza do erro proporcional no preço, e não do erro relativo na escala logarítmica — coerente, ademais, com um MAE de 0,165 em ln, equivalente a um desvio multiplicativo de cerca de 18% no valor unitário. O R^2 mede a fração da variância explicada; RMSE e MAE quantificam a magnitude dos erros em unidades logarítmicas; e o MAPE, o erro percentual médio sobre o preço unitário. Conforme discutido na Seção 2.7, essas métricas constituem indicadores de desempenho preditivo e não se confundem com os critérios normativos de grau de fundamentação e de precisão da ABNT NBR 14653-2, cujo enquadramento de precisão se baseia na amplitude do intervalo de confiança de 80% em torno do valor estimado.

5 Resultados

5.1 Desempenho comparativo

A Tabela 3 sintetiza o desempenho das seis abordagens no conjunto de teste e a Figura 3 compara o R^2 e o RMSE entre os conjuntos de treino, validação e teste. A KAN obteve o melhor resultado (R^2 = 0,716), seguida pela equação destilada KAN+SR (0,665), pelo OLS com Box–Cox (0,661), pela MLP de uma camada (0,638), pela regressão simbólica isolada (0,608) e pela MLP de duas camadas (0,600). A diferença reduzida entre treino e teste da KAN (ΔR^2 = 0,013) indica boa capacidade de generalização. As diferenças entre os modelos intermediários — KAN+SR (0,665), OLS (0,661) e MLP de uma camada (0,638) — são pequenas, da ordem de poucos milésimos a centésimos de R^2, e devem ser lidas à luz da incerteza amostral (Seção 6.3), e não como ordenação definitiva; sua confirmação requer repetição com múltiplas sementes e intervalos de confiança.

Tabela 3 — Métricas de desempenho no conjunto de teste, em ordem decrescente de R^2.

Modelo	R^2	RMSE	MAE	MAPE	Parâm./op.
KAN [12→6→1]	0,716	0,219	0,165	16,7%	≈ 1.014
KAN+SR (compl. 19)	0,665	0,237	0,181	18,3%	19 op.
OLS Box–Cox	0,661	0,239	0,180	18,0%	11 coef.
MLP 1 camada [12→24→1]	0,638	0,247	0,189	18,5%	337
SR isolada	0,608	0,257	0,193	19,8%	≈ 90 op.
MLP 2 camadas [12→24→12→1]	0,600	0,259	0,198	18,5%	625

Fonte: elaboração própria.

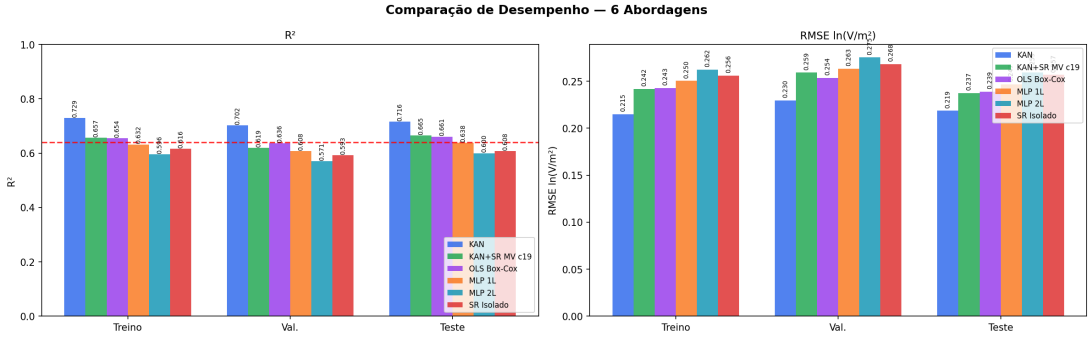


Figura 3 — Comparação de R^2 (esquerda) e RMSE (direita) das seis abordagens nos conjuntos de treino, validação e teste. A linha tracejada em R^2 = 0,64 é apenas um referencial visual de leitura; ressalva-se (Seção 2.7) que a NBR 14653-2 não define limiar de R^2 para enquadramento.

Fonte: elaboração própria.

5.2 KAN — melhor desempenho e interpretabilidade

Além do melhor desempenho, a KAN destacou-se pela interpretabilidade estrutural. A Figura 4 ordena as variáveis pela amplitude do efeito marginal aprendido pela rede. O valor venal do m² de terreno — oriundo da planta genérica de valores do IPTU — é, de longe, o preditor dominante (amplitude de 1,090 em ln(V/m²)), seguido pelo fator de obsolescência (0,438), pelo padrão construtivo (0,347) e pelo valor do m² de construção (0,321). No extremo inferior, o CEP normalizado (0,125) e a área construída (0,100) apresentam as menores amplitudes, confirmando, no caso do CEP, a limitação discutida na Seção 4.3. Essa leitura, análoga à dos coeficientes de um modelo hedônico, é diretamente acessível ao avaliador e fornece subsídio à crítica econômica do modelo.

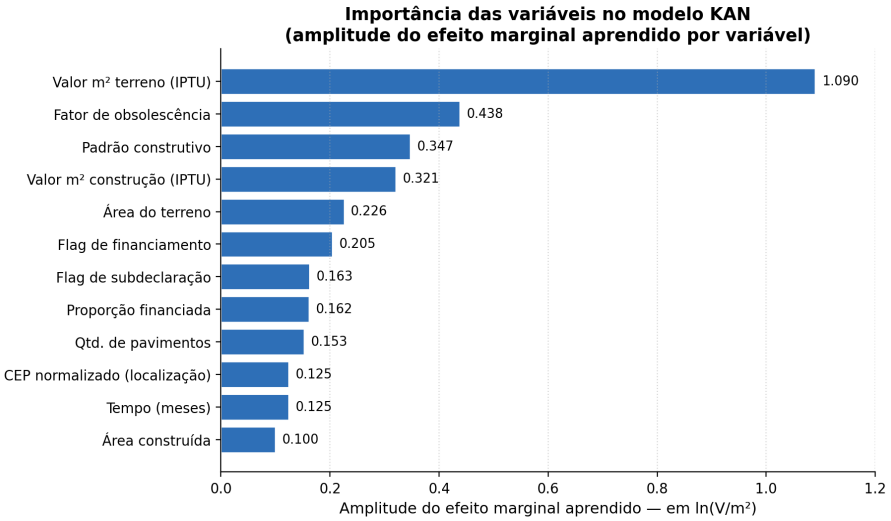


Figura 4 — Importância das variáveis no modelo KAN, medida pela amplitude do efeito marginal aprendido em cada aresta (em ln(V/m²)).

Fonte: elaboração própria.

5.3 KAN+SR — equação simbólica frente ao modelo linear

A destilação multivariada produziu uma equação compacta — seis variáveis e quatro termos aditivos — que reproduz a saída da KAN com fidelidade $R^2 = 0{,}900$ no conjunto de teste. A expressão selecionada (complexidade 19), com as variáveis em escala normalizada [0,1], é:

$$\ln(V/m^2) = 7{,}6153 + \sqrt{(\text{valor_m2_terreno} \times 1{,}9699)} + (\text{valor_m2_construcao} + \text{area_terreno_m2}) \times 0{,}4585 + (\text{fator_obsolescencia} - \text{flag_subdeclaracao})^3 \times \text{padrao_ordinal}$$

A estrutura é economicamente interpretável: a raiz quadrada do valor venal do terreno traduz retornos marginais decrescentes; o segundo termo combina, em escala normalizada, o valor unitário de construção e a área do terreno. Ressalve-se que essa parcela se refere à área do terreno, não ao seu valor unitário: a soma, embora matematicamente válida por operar sobre variáveis normalizadas no intervalo [0,1], não representa equivalência econômica direta entre valores. O termo cúbico, por sua vez, capta uma interação entre obsolescência, padrão construtivo e a variável binária de subdeclaração — termo cujo sinal pode inverter-se quando a subdeclaração é sinalizada, de modo que sua plausibilidade no domínio observado é objeto de análise de resposta recomendada (Seção 6.4); recomenda-se, ademais, restringir a aplicação da equação ao domínio de treino das variáveis (Anexo A) e, antes de seu uso em laudo, verificar a monotonicidade e a estabilidade de cada termo no intervalo observado. Com $R^2 = 0{,}665$ no teste, a equação apresenta resultado pontual ligeiramente superior ao do OLS (0,661) e à MLP de uma camada (0,638); dada a pequena magnitude dessas diferenças (Seção 6.3), há, na prática, equivalência de desempenho, com a vantagem distintiva de a equação destilada oferecer forma fechada e diretamente auditável — ao contrário das redes neurais — e sem fixar a priori a forma funcional. A equação destilada, em escala normalizada, e os parâmetros de normalização necessários à conversão para a escala original das variáveis constam do Anexo A.

5.4 OLS Box–Cox — referência normativa clássica

O modelo OLS com transformações de Box–Cox alcançou $R^2 = 0{,}661$, com dez coeficientes angulares estatisticamente significativos ($p < 0{,}001$), além do intercepto — onze parâmetros no total; sua forma compacta consta do Anexo B. Os diagnósticos, contudo, revelam violações das hipóteses clássicas: os testes de Breusch–Pagan ($LM = 520{,}7$; $p \approx 0$) e de White ($LM = 1.061{,}8$; $p \approx 0$) acusam heterocedasticidade — violação da homocedasticidade, pressuposto

de que a variância dos erros é constante ao longo de toda a faixa de valores preditos —, e os de Shapiro–Wilk e Jarque–Bera (JB = 5.640) rejeitam a normalidade dos resíduos (assimetria 0,21; curtose excedente 3,57). Em contrapartida, o estatístico de Durbin–Watson (1,99) não indica autocorrelação e os fatores de inflação de variância (VIF < 10) afastam multicolinearidade relevante. A heterocedasticidade não enviesa as estimativas pontuais, mas compromete a eficiência dos estimadores e invalida os testes de hipótese e os intervalos de confiança calculados pelas fórmulas clássicas, demandando erros-padrão robustos à heterocedasticidade (HC3) para fins inferenciais (WHITE, 1980). A não normalidade dos resíduos, por sua vez, fragiliza a inferência em amostras menores e impõe cautela na interpretação de valores extremos. Essas violações indicam que o OLS, apesar de seu bom desempenho preditivo neste contexto, apresenta limitações relevantes para uso efetivo em laudos que dependam de intervalos de confiança formalmente válidos: sem correção, os erros-padrão seriam subestimados e os graus de precisão calculados poderiam ser superestimados. A adequação plena do modelo exigiria, no mínimo, a aplicação de erros-padrão robustos (HC3) e, possivelmente, a revisão da especificação funcional para reduzir a heterocedasticidade residual.

5.5 Redes MLP

As redes MLP situaram-se abaixo das demais abordagens. A de uma camada oculta [12 → 24 → 1] obteve $R^2 = 0{,}638$, a poucos centésimos do OLS, apesar de seus 337 parâmetros. A de duas camadas [12 → 24 → 12 → 1], com 625 parâmetros, apresentou desempenho inferior ($R^2 = 0{,}600$): o acréscimo de profundidade, em arquitetura estreita, não melhorou — e até degradou — o ajuste, possivelmente em razão da maior dificuldade de otimização e de uma regularização desproporcional à capacidade da rede. O contraste com a KAN, de profundidade equivalente, é examinado na Seção 6.

5.6 Regressão simbólica isolada

A regressão simbólica isolada, ajustada diretamente aos dados por backfitting sequencial, atingiu $R^2 = 0{,}608$, superando — com uma fórmula aditiva simples — a MLP de duas camadas. O resultado evidencia a riqueza das relações recuperáveis por expressões simbólicas, ainda que aquém da destilação a partir da KAN, que se beneficia da captura de interações pela rede neural.

5.7 Análise gráfica — previstos vs. observados e resíduos por padrão

As Figuras 5 e 6 examinam o comportamento dos modelos. Na dispersão entre valores previstos e observados (Figura 5), a KAN apresenta a nuvem mais homogênea em torno da diagonal; KAN+SR e OLS exibem padrão visual semelhante; e as MLP dispersam-se mais nos extremos da distribuição de preços. A análise dos resíduos por padrão construtivo (Figura 6) mostra a KAN com resíduos centrados em zero em todos os padrões, enquanto o OLS e as MLP tendem a subestimar levemente os padrões extremos (1 e 6), sinalizando dificuldade em capturar a não linearidade nesses segmentos.

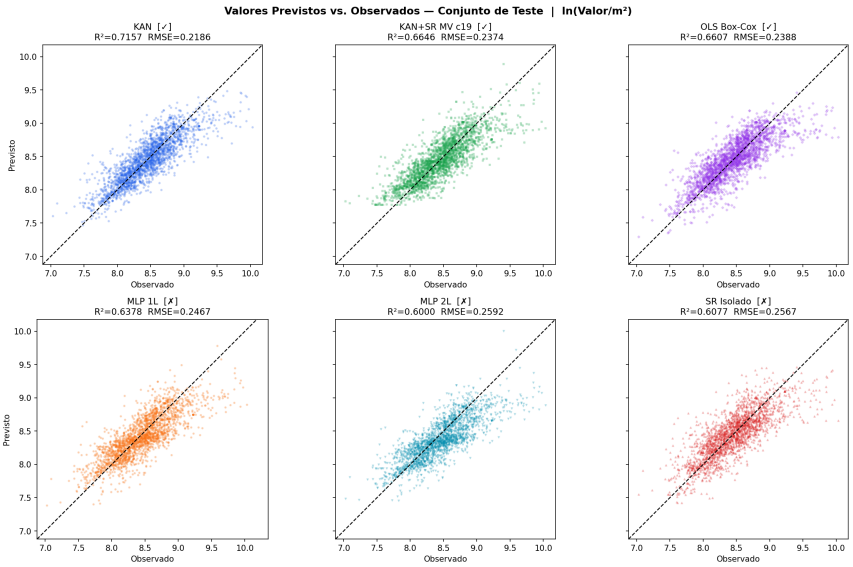


Figura 5 — Valores previstos vs. observados no conjunto de teste para as seis abordagens. A diagonal tracejada representa a predição perfeita.

Fonte: elaboração própria.

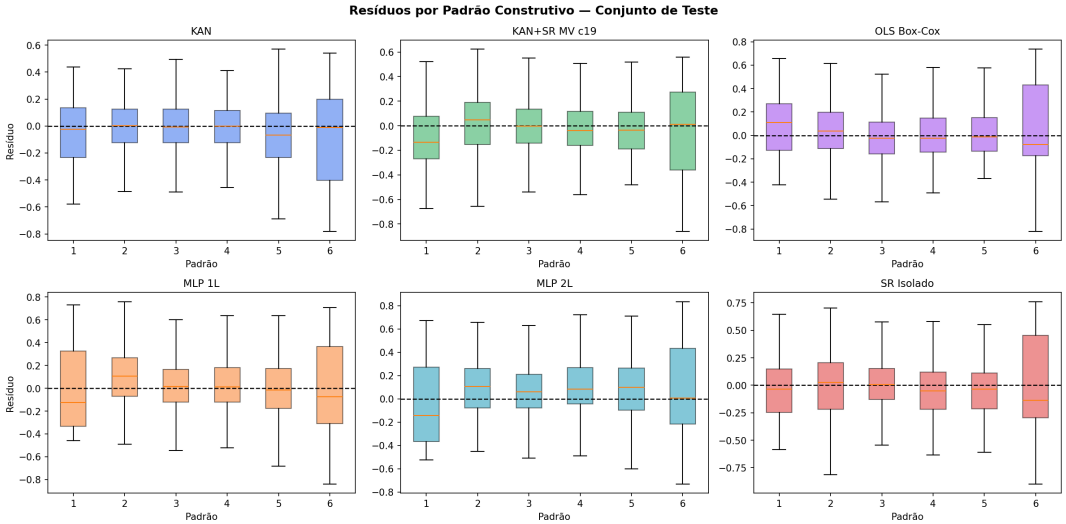


Figura 6 — Distribuição dos resíduos por padrão construtivo (1 = popular … 6 = fino). A linha tracejada marca o resíduo nulo.

Fonte: elaboração própria.

5.8 Análise dos resíduos em função dos valores previstos

A Figura 7 apresenta, para cada uma das seis abordagens, o diagrama de dispersão dos resíduos (y_observado − y_previsto, em escala de ln(V/m²)) em função dos valores previstos no conjunto de teste. A linha tracejada horizontal marca o resíduo nulo; a curva vermelha, a tendência média dos resíduos por faixa de valor previsto, estimada por binagem de percentis. Essa análise complementa as métricas globais, revelando padrões sistemáticos de viés e heterocedasticidade que os escalares R² e RMSE não capturam.

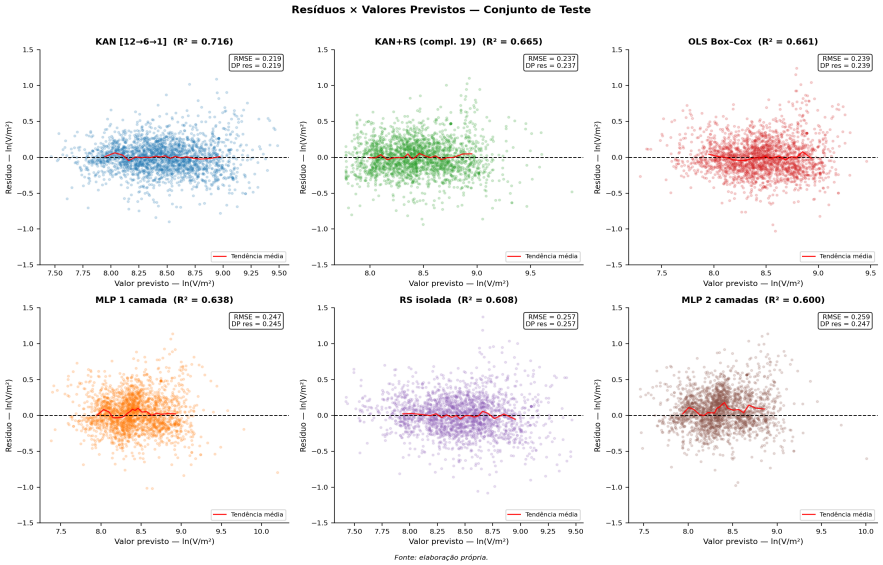


Figura 7 — Resíduos em função dos valores previstos (conjunto de teste) para as seis abordagens. A linha tracejada marca o resíduo nulo; a curva vermelha indica a tendência média por faixa de valor previsto.
Fonte: elaboração própria.

A análise revela comportamentos distintos entre os modelos. Na KAN, a dispersão dos resíduos é aproximadamente simétrica em torno de zero ao longo de toda a faixa de valores previstos, e a curva de tendência mantém-se próxima ao eixo horizontal, indicando ausência de viés sistemático e variância razoavelmente estável — comportamento compatível com homocedasticidade condicional e alinhado com o desempenho superior no teste (R^2 = 0,716, RMSE = 0,219). O padrão da KAN+SR é semelhante ao da KAN em termos de centralidade dos resíduos, com leve alargamento da nuvem nas extremidades da distribuição, reflexo da perda controlada de fidelidade na destilação (R^2 de fidelidade = 0,900); a tendência média permanece próxima de zero, confirmando ausência de viés estrutural. O OLS, embora apresente R^2 próximo ao da KAN+SR (0,661), exibe heterocedasticidade visível: a variância dos resíduos cresce nos extremos inferiores e superiores da distribuição de preços, padrão consistente com os testes formais de Breusch–Pagan e White reportados na Seção 5.4. A curva de tendência apresenta ligeira curvatura nas pontas, indício residual de não linearidades não capturadas pela especificação Box–Cox. A MLP de uma camada apresenta distribuição de resíduos similar à do OLS em termos de forma, porém com maior dispersão geral (RMSE = 0,247), sem evidência de viés sistemático pronunciado. A MLP de duas camadas mostra padrão de resíduos levemente mais instável e maior variabilidade nas extremidades, possivelmente associada à dificuldade de otimização da arquitetura mais profunda. A regressão simbólica isolada exibe a maior dispersão entre os modelos (RMSE = 0,257), com variância crescente nos valores mais elevados — limitação decorrente de sua estrutura aditiva unidimensional, que não captura as interações entre variáveis que os demais modelos recuperam via composição de funções ou programação genética multivariada.

Em síntese, a análise dos resíduos em função dos valores previstos reforça o ordenamento já observado nas métricas globais: a KAN apresenta o comportamento mais regular e centrado; a KAN+SR mantém o padrão de ausência de viés com leve aumento de dispersão; o OLS demonstra heterocedasticidade estrutural com implicações para a inferência formal; e as MLP e a SR isolada apresentam variabilidade crescente nos extremos, indicando menor capacidade de generalização nesses segmentos de mercado.

6 Discussão

A Tabela 4 organiza os modelos segundo a estrutura, o tipo de equação produzida, a quantidade de parâmetros ou operações e o desempenho no teste, sintetizando o compromisso entre capacidade preditiva e transparência.

Tabela 4 — Estrutura, tipo de equação e desempenho das abordagens.

Modelo	Estrutura	Tipo de equação	Parâm./op.	R^2 Teste
KAN	78 B-splines aprendidas	Implícita	≈ 1.014	0,716
KAN+SR (c19)	6 variáveis, 4 termos	Simbólica fechada	19 op.	0,665
OLS Box–Cox	10 coeficientes	Algébrica fechada	11 coef.	0,661
MLP 1 camada	1 camada oculta (ReLU)	Implícita (caixa-preta)	337	0,638
SR isolada	12 equações aditivas 1D	Simbólica fechada	≈ 90 op.	0,608
MLP 2 camadas	2 camadas ocultas (ReLU)	Implícita (caixa-preta)	625	0,600

Fonte: elaboração própria.

6.1 KAN frente à MLP: a vantagem das B-splines

A comparação mais informativa do experimento é a que opõe KAN e MLP sob profundidade semelhante (duas camadas após a entrada). A KAN apresenta $\Delta R^2 \approx 0{,}078$ sobre a MLP de uma camada. É preciso reconhecer, porém, que as arquiteturas não têm orçamento de parâmetros equiparado (≈ 1.014 na KAN contra 337 na MLP de uma camada), de modo que a diferença observada não isola, por si só, o efeito das funções de aresta: ela reflete, conjuntamente, a natureza das B-splines e a maior capacidade da rede. Ainda assim, dois indícios apontam para a contribuição qualitativa das B-splines: o ganho por parâmetro é favorável à KAN e, sobretudo, a MLP de duas camadas (625 parâmetros) não supera a de uma camada, o que sugere que o mero acréscimo de capacidade não explica o desempenho. Reconhece-se, em particular, que o espaço de hiperparâmetros das MLP pode ter sido menos exaustivamente explorado que o da KAN — a convergência instável da configuração MLP_2L_A (Anexo C) é indício disso —, de modo que a comparação não é estritamente controlada quanto ao esforço de ajuste (*tuning effort*). Um teste controlado em sentido estrito exigiria equiparar o orçamento de parâmetros e de busca entre as famílias e repetir o treinamento com múltiplas sementes, relatando média, desvio-padrão e intervalos de confiança — desdobramento recomendado (Seção 6.4). Para as relações suaves e majoritariamente monótonas do mercado imobiliário — como a dependência log-linear em relação ao valor do terreno —, as B-splines mostram-se mais expressivas do que as ativações ReLU fixas, o que se reflete na menor dispersão dos resíduos nos extremos (Figuras 5 e 6).

6.2 Interpretabilidade e auditabilidade

Sob a ótica da engenharia de avaliações, o achado central é que a destilação KAN+SR entrega uma equação fechada de quatro termos que iguala ou supera levemente o modelo linear clássico — sem fixar a priori a forma funcional — e permanece diretamente inspecionável e auditável, ao contrário das MLP, irredutivelmente opacas. Recupera-se, assim, a transparência exigida em laudos e perícias sem renunciar à capacidade de capturar não linearidades e interações. A KAN, por sua vez, ainda que não produza equação fechada, oferece interpretabilidade estrutural por meio dos perfis marginais e do ordenamento de importância das variáveis (Figura 4), úteis à crítica do modelo.

6.3 Aderência normativa e juízo profissional

Quanto ao enquadramento normativo, reitera-se que a ABNT NBR 14653-2 não fixa limiares de R^2 (Seção 2.7). O enquadramento formal quanto ao grau de precisão requer o cálculo da amplitude do intervalo de confiança de 80% em torno do valor estimado — imediato para o modelo paramétrico (OLS) e estimável por reamostragem (bootstrap) (EFRON; TIBSHIRANI, 1993) para os modelos de aprendizado, etapa recomendada para a consolidação de um laudo. No caso do OLS, todavia, o cálculo formal desse intervalo pressupõe a validade das hipóteses clássicas; em face das violações de homocedasticidade e normalidade dos resíduos documentadas na Seção 5.4, a amplitude calculada pelas fórmulas padrão seria subestimada, comprometendo o enquadramento do grau de precisão. Para uso efetivo em laudo, seria necessário empregar erros-padrão robustos (HC3) ou revisitar a especificação do modelo.

Mais relevante para o lema do congresso é o papel do juízo profissional: a equação simbólica devolve ao avaliador a capacidade de inspecionar, criticar e validar economicamente o modelo, mantendo a inteligência artificial como ferramenta subordinada à decisão técnica, e não como substituta dela. O profissional permanece responsável pela seleção das variáveis, pela validação da sanidade econômica da equação e pela fundamentação do laudo.

6.4 Limitações

O estudo apresenta limitações que delimitam o alcance das conclusões. A variável de localização (CEP) é uma aproximação de baixa granularidade, a ser substituída por coordenadas geográficas e indicadores de acessibilidade. O recorte a apartamentos de um único município restringe a generalização para outras tipologias e mercados. A divisão amostral foi estratificada por padrão construtivo, porém aleatória quanto à localização: não se controlou a eventual presença do mesmo imóvel, edifício ou microárea simultaneamente em treino e teste, o que pode introduzir dependência espacial e otimismo nas métricas; recomenda-se, em trabalhos futuros, validação por grupos (group split por identificador cadastral ou edifício), validação espacial por blocos com reporte do I de Moran dos resíduos e holdout temporal (por exemplo, treinar em 2021 e testar em 2022). A vantagem da KAN+SR sobre o OLS é de pequena magnitude ($\Delta R^2 = 0{,}004$) e foi obtida sem quantificação formal de incerteza; sua confirmação exige repetição com múltiplas sementes, reamostragem (bootstrap) e intervalos de confiança, bem como um protocolo que reserve a seleção da equação ao conjunto de validação e restrinja o teste a uma única avaliação (Seção 3.4). As variáveis transacionais de controle declaratório (Seção 4.1) merecem análise de sensibilidade que separe seu uso pós-transação do uso estritamente preditivo. A destilação simbólica, embora fiel, não reproduz integralmente a KAN ($R^2 = 0{,}900$), implicando perda controlada de desempenho em relação à rede. Por fim, a validação completa para fins de laudo — intervalos de confiança de 80%, identificação de pontos influentes e estimadores robustos — constitui desdobramento natural e recomendado deste trabalho.

7 Conclusões

Este trabalho comparou seis abordagens de modelagem para a avaliação de apartamentos residenciais em São Paulo, com foco na conciliação entre capacidade preditiva e transparência. A rede Kolmogorov–Arnold obteve o melhor desempenho ($R^2 = 0{,}716$ no teste), superando o modelo linear clássico e as redes MLP de profundidade semelhante. A comparação entre KAN e MLP sugere que a vantagem decorre, em boa medida, da natureza das funções de aresta aprendidas (B-splines), e não apenas da profundidade — embora a diferença de orçamento de parâmetros entre as arquiteturas recomende cautela e validação adicional com orçamentos equiparados e múltiplas sementes (Seção 6.1).

A principal contribuição reside na demonstração de que a destilação da KAN por regressão simbólica produz uma equação fechada, compacta e auditável, que iguala ou supera levemente o modelo OLS — sem fixar a priori a forma funcional. Reitere-se, contudo, que o $R^2 = 0{,}665$ da equação destilada é uma estimativa pontual otimista, condicionada à inspeção do conjunto de teste na seleção da expressão (Seção 3.4); sua confirmação como métrica de generalização não enviesada depende de um protocolo em que a expressão seja selecionada apenas no conjunto de validação. Esse resultado é especialmente relevante para a engenharia de avaliações, a perícia judicial e as aplicações regulatórias, nas quais a reprodutibilidade e a explicação formal do valor estimado são requisitos essenciais. A abordagem híbrida KAN+SR supera, assim, a dicotomia tradicional entre modelos lineares interpretáveis e modelos de aprendizado de alta complexidade, porém opacos.

Como desdobramentos, recomendam-se: a substituição do CEP por coordenadas geográficas e variáveis de acessibilidade; o cálculo dos intervalos de confiança de 80% para o enquadramento formal de precisão segundo a NBR 14653-2; a aplicação de estimadores robustos ao OLS; a validação espacial e temporal e a quantificação de incerteza por reamostragem; e a extensão do experimento a outras tipologias e mercados. Ainda assim, os

resultados sustentam o potencial da combinação KAN+SR como alternativa metodológica promissora e transparente, cujo enquadramento normativo pleno permanece sujeito a validação adicional, na qual a inteligência artificial atua a serviço — e não em substituição — do juízo profissional.

A relevância desse posicionamento é reforçada pelo arcabouço normativo internacional. O International Valuation Standards Council (IVSC), em seu Perspectives Paper de 2025, define o Modelo de Avaliação Automatizado (AVM — Automated Valuation Model) como um tipo de modelo que provê o cálculo automatizado de valor para um ativo específico em uma data específica, utilizando um algoritmo ou outras técnicas de cálculo sem que o avaliador aplique julgamento profissional sobre o modelo, incluindo a avaliação e seleção de entradas ou a revisão dos resultados (IVSC, 2025, p. 4). Por essa definição, um AVM convencional, isoladamente, exclui a intervenção crítica do profissional — e, portanto, não produz, por si só, uma avaliação em conformidade com os IVS. Isso não impede, contudo, que modelos automatizados auxiliem o avaliador, desde que este compreenda, selecione e revise criticamente o modelo — precisamente o que a forma fechada da equação destilada viabiliza. A abordagem KAN+SR proposta neste trabalho posiciona-se deliberadamente nessa direção: ao converter o modelo de aprendizado em uma equação algébrica fechada, inspecionável e auditável, ela preserva a interpretabilidade das decisões e devolve ao avaliador o controle pleno sobre o processo. O profissional pode verificar a plausibilidade econômica de cada termo da equação, identificar anomalias, ajustar o escopo de aplicação e sustentar tecnicamente o valor perante terceiros — requisitos que os AVMs black-box, amplamente utilizados por instituições financeiras, não satisfazem. Nesse sentido, a destilação simbólica representa não apenas um ganho preditivo, mas uma resposta metodológica ao desafio de integrar inteligência artificial à avaliação imobiliária de forma transparente, auditável e profissionalmente responsável.

Nota metodológica sobre o uso de inteligência artificial

Foram utilizadas ferramentas de IA Generativa como suporte. O Anthropic Claude Opus 4.8 e Sonnet 4.6 e o OpenAI Codex GPT-5.5 foram aplicados na revisão de texto, pesquisa bibliográfica e geração de imagens. Os modelos — rede Kolmogorov–Arnold, regressão simbólica (PySR), regressão linear (OLS) e redes MLP — foram implementados e treinados pelo autor em linguagem Python, com auxílio do Claude Code (modelo Opus 4.8) e do Open AI Codex (modelo GPT-5.5), e todos os resultados reportados decorrem diretamente desses experimentos sobre a base de dados descrita na Seção 4.

Declaração de conformidade. Os autores declaram que o presente trabalho é original, cumpre integralmente as condições estabelecidas no Regulamento do Concurso de Ponencias Técnicas do Congresso UPAV 2026 e adere às normas de propriedade intelectual aplicáveis. Declaram, ainda, que o uso de ferramentas de inteligência artificial se deu como apoio à elaboração, conforme detalhado nesta nota metodológica, sem substituir a análise profissional nem a elaboração original do trabalho, cuja contribuição intelectual é de responsabilidade dos autores.

Referências

ANELLI, D.; MORANO, P.; TAJANI, F.; GUARINI, M. R. The interpretative effects of normalization techniques on complex regression modeling: an application to real estate values using machine learning. Information, Basel, v. 16, n. 486, 2025.

ARNOLD, V. I. On functions of three variables. Doklady Akademii Nauk SSSR, Moscou, v. 114, p. 679–681, 1957.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 14653-1: avaliação de bens — Parte 1: procedimentos gerais. Rio de Janeiro: ABNT, 2019.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 14653-2: avaliação de bens — Parte 2: imóveis urbanos. Rio de Janeiro: ABNT, 2011.

BIDERMAN, C. Forças de atração e expulsão na grande São Paulo. In: ABRAMO, P. (org.). A cidade da informalidade. Rio de Janeiro: Sette Letras/FAPERJ, 2008. p. 57–80.

BISHOP, C. M. Pattern recognition and machine learning. Nova York: Springer, 2006.

BOX, G. E. P.; COX, D. R. An analysis of transformations. Journal of the Royal Statistical Society: Series B, Londres, v. 26, n. 2, p. 211–252, 1964.

CRANMER, M. Interpretable machine learning for science with PySR and SymbolicRegression.jl. arXiv:2305.01582, 2023.

CYBENKO, G. Approximation by superpositions of a sigmoidal function. Mathematics of Control, Signals and Systems, Londres, v. 2, n. 4, p. 303–314, 1989.

DRACHAL, K.; PAWLOWSKI, M. Forecasting selected commodities prices with the Bayesian symbolic regression. International Journal of Financial Studies, Basel, v. 12, n. 34, 2024.

EFRON, B.; TIBSHIRANI, R. J. An introduction to the bootstrap. Nova York: Chapman & Hall, 1993.

EMPRESA BRASILEIRA DE CORREIOS E TELÉGRAFOS (ECT). Guia postal brasileiro. Brasília: ECT, 1971.

GENET, R.; INZIRILLO, H. TKAN: Temporal Kolmogorov-Arnold Networks. arXiv:2405.07344, 2024.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep learning. Cambridge: MIT Press, 2016.

GOODMAN, A. C.; THIBODEAU, T. G. Housing market segmentation. Journal of Housing Economics, Amsterdã, v. 7, n. 2, p. 121–143, 1998.

GREENE, W. H. Econometric analysis. 8. ed. Nova York: Pearson Education, 2018.

HAYKIN, S. Neural networks and learning machines. 3. ed. Upper Saddle River: Prentice Hall, 2009.

HINTON, G.; VINYALS, O.; DEAN, J. Distilling the knowledge in a neural network. arXiv:1503.02531, 2015.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multilayer feedforward networks are universal approximators. Neural Networks, Amsterdã, v. 2, n. 5, p. 359–366, 1989.

HWANG, S.; THILL, J. C. Delineating urban housing submarkets with fuzzy clustering. Environment and Planning B: Planning and Design, Londres, v. 36, n. 5, p. 865–882, 2009.

INTERNATIONAL VALUATION STANDARDS COUNCIL (IVSC). Navigating the rise of artificial intelligence in valuation: opportunities, risks, and standards. Londres: IVSC, jul. 2025. (Perspectives Paper).

KINGMA, D. P.; BA, J. Adam: a method for stochastic optimization. arXiv:1412.6980, 2015.

KOLMOGOROV, A. N. On the representation of continuous functions of several variables by superpositions of continuous functions of one variable and addition. Doklady Akademii Nauk SSSR, Moscou, v. 114, p. 953–956, 1957.

KOZA, J. R. Genetic programming as a means for programming computers by natural selection. Statistics and Computing, Londres, v. 4, n. 2, p. 87–112, 1994.

LIU, Z. et al. KAN: Kolmogorov–Arnold networks. arXiv:2404.19756, 2024.

MALPEZZI, S. Hedonic pricing models: a selective and applied review. In: O'SULLIVAN, T.; GIBB, K. (org.). Housing economics and public policy. Oxford: Blackwell Publishing, 2003. p. 67–89.

MORA-GARCIA, R. T.; CESPEDES-LOPEZ, M. F.; PEREZ-SANCHEZ, V. R. Housing price prediction using machine learning algorithms in COVID-19 times. Land, Basel, v. 11, n. 11, artigo 2100, 2022. DOI: 10.3390/land11112100.

PREFEITURA DO MUNICÍPIO DE SÃO PAULO. Dados abertos: conjunto do Imposto de Transmissão de Bens Imóveis (ITBI) e cadastro do IPTU — Planta Genérica de Valores e atributos físicos (TPCL), exercícios de 2021 e 2022. São Paulo: PMSP, Portal de Dados Abertos, 2026. Disponível em: https://dados.prefeitura.sp.gov.br. Acesso em: jun. 2026.

ROSEN, S. Hedonic prices and implicit markets: product differentiation in pure competition. Journal of Political Economy, Chicago, v. 82, n. 1, p. 34–55, 1974.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence, Londres, v. 1, n. 5, p. 206–215, 2019. DOI: 10.1038/s42256-019-0048-x.

SCHMIDT, M.; LIPSON, H. Distilling free-form natural laws from experimental data. Science, Washington, v. 324, n. 5923, p. 81–85, 2009.

SOUZA NETO, J.N.A.; MIURA, J; LADEIRA, M. (COBREAP). Estimativa de valores de imóveis da União com técnicas de aprendizagem de máquina e componentes espaciais. In: Anais do COBREAP 2023. São Paulo: IBAPE/SP, 2023.

VIKTORATOS, I.; TSADIRAS, A. Advancing real-estate forecasting: a novel approach using Kolmogorov-Arnold Networks. Algorithms, Basel, v. 18, n. 93, 2025.

WHITE, H. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. Econometrica, Nova York, v. 48, n. 4, p. 817–838, 1980.

WOOLDRIDGE, J. M. Introductory econometrics: a modern approach. 6. ed. Boston: Cengage Learning, 2016.

ZUO, X.; JIANG, A. Symbolic modeling for financial asset pricing. The Journal of Finance and Data Science, Amsterdam, v. 11, artigo 100150, 2025.

ZURADA, J.; LEVITAN, A.; GUAN, J. A comparison of regression and artificial intelligence methods in a mass appraisal context. Journal of Real Estate Research, v. 33, n. 3, p. 349–388, 2011. DOI: 10.1080/10835547.2011.12091311.

Anexos

Os anexos reúnem as formulações completas dos modelos. As variáveis nas equações em escala normalizada referem-se ao intervalo [0,1] obtido por transformação MinMax com parâmetros do conjunto de treino.

Anexo A — Equação simbólica KAN+SR (complexidade 19)

Equação destilada da rede KAN, em escala normalizada das variáveis (fidelidade à KAN: $R^2 = 0{,}900$ no teste):

$$\ln(V/m^2) = 7{,}6153 + \sqrt{(valor_m2_terreno \times 1{,}9699)} + (valor_m2_construcao + area_terreno_m2) \times 0{,}4585 + (fator_obsolescencia - flag_subdeclaracao)^3 \times padrao_ordinal$$

A conversão para a escala original de cada variável é obtida pela inversa da normalização MinMax, x_norm = (x_orig − mínimo)/amplitude, com os parâmetros do conjunto de treino indicados na Tabela A.1.

Tabela A.1 — Parâmetros de normalização (conjunto de treino) das variáveis da equação.

Variável	Mínimo	Amplitude
valor_m2_terreno (R$/m²)	126	25.914
valor_m2_construcao (R$/m²)	1.291	2.499
area_terreno_m2 (m²)	89	233.314
fator_obsolescencia	0,20	0,79
padrao_ordinal	1	5
flag_subdeclaracao	binária (0/1)	—

Fonte: elaboração própria.

Anexo B — Modelo OLS com transformações Box–Cox

Equação estimada (dez coeficientes, todos com $p < 0{,}001$):

$$\ln(V/m^2) = 5{,}0044 + 0{,}2909 \cdot \ln(valor_m2_terreno) + 0{,}8654 \cdot fator_obsolescencia^2 - 0{,}2741 \cdot flag_subdeclaracao + 0{,}0008 \cdot valor_m2_construcao^{0{,}814} + 0{,}1526 \cdot \ln(area_terreno) + 0{,}1211 \cdot cep_norm - 0{,}0096 \cdot qtd_pavimentos^{0{,}731} + 0{,}0025 \cdot t_ordinal + 0{,}0306 \cdot flag_financiamento + 0{,}0230 \cdot padrao_ordinal$$

Tabela B.1 — Diagnósticos estatísticos do modelo OLS.

Teste	Estatística	Interpretação
Breusch–Pagan	LM = 520,7 (p aprox. 0)	Heterocedasticidade
White	LM = 1.061,8 (p aprox. 0)	Heterocedasticidade
Shapiro–Wilk	p aprox. 0	Não-normalidade dos resíduos
Jarque–Bera	JB = 5.640	Assimetria 0,21; curtose excedente 3,57
Durbin–Watson	1,99	Ausência de autocorrelação
VIF	< 10	Ausência de multicolinearidade relevante

Fonte: elaboração própria.

Anexo C — Redes MLP avaliadas

Formulação geral da MLP de uma camada oculta: $\hat{y} = W_2 \cdot \mathrm{ReLU}(W_1 \cdot x + b_1) + b_2$, com $W_1 \in \mathbb{R}^{24 \times 12}$ e $W_2 \in \mathbb{R}^{1 \times 24}$. A variante de duas camadas acrescenta uma camada ReLU intermediária (24 → 12). A Tabela C.1 resume as arquiteturas avaliadas; selecionou-se a melhor de cada grupo pelo R^2 de validação.

Tabela C.1 — Arquiteturas MLP avaliadas (estrela = selecionada).

Configuração	Arquitetura	Parâmetros	R^2 teste
MLP_1L_A	[12 → 16 → 1]	225	0,628
MLP_1L_B (sel.)	[12 → 24 → 1]	337	0,638
MLP_2L_A	[12 → 16 → 8 → 1]	353	0,358
MLP_2L_B (sel.)	[12 → 24 → 12 → 1]	625	0,600

Fonte: elaboração própria.

A configuração MLP_2L_A apresentou convergência instável (R^2 = 0,358), confirmando a dificuldade de otimização de arquiteturas profundas e estreitas com regularização por dropout.

Anexo D — Algoritmo de transformação do CEP

A Tabela D.1 detalha a conversão do CEP em variável contínua normalizada (cep_norm), conforme a Seção 4.3.

Tabela D.1 — Etapas de transformação do CEP em variável normalizada.

Etapa	Operação	Exemplo
1	Leitura do CEP do ITBI	01310-100
2	Remoção de não-dígitos e padronização (8 dígitos)	01310100
3	Conversão para inteiro	1.310.100
4	Normalização MinMax (treino): (cep - 1.004.010)/7.486.790	0,0408
5	Alimentação ao modelo	cep_norm entre 0 e 1

Fonte: elaboração própria.

O valor 0 corresponde ao CEP mais central da amostra (01004-010, Praça da Sé) e o valor 1 ao mais periférico (08490-800, extremo leste). Parâmetros de mínimo (1.004.010) e amplitude (7.486.790) fixados no conjunto de treino.

Anexo E — Comparativo das métricas KAN, SR isolada, KAN+SR, OLS Box-Cox e RNA MLP 1L e 2L

Modelo	R^2 Teste	RMSE	MAPE	Param./Ops.
KAN [12→6→1]	0,7157	0,2186	16,7%	~1014
KAN+SR MV (c19)	0,6646	0,2374	18,3%	19 ops
OLS Box-Cox	0,6607	0,2388	18,0%	11 coef
MLP 1L [12→24→1]	0,6378	0,2467	18,5%	337
SR isolada	0,6077	0,2567	19,8%	~90 ops
MLP 2L [12→24→12→1]	0,6000	0,2592	18,5%	625

Fonte: elaboração própria.